

Optimasi Akurasi Klasifikasi Sentimen Ulasan Menggunakan *Threshold Tuning* pada Arsitektur Hibrida IndoBERT-CNN-BiLSTM-Attention

Arief Sidik Wijayanto
Jurusan Teknik Informatika
STMIK Widya Utama
Jl. Sunan Kalijaga, Indonesia
ariefsidik2016@gmail.com

Agil Karuniati
Jurusan Teknik Informatika
STMIK Widya Utama
Jl. Sunan Kalijaga, Indonesia
agilkaruniati@gmail.com

Rizqi Aulia Rahman
Jurusan Teknik Informatika
STMIK Widya Utama
Jl. Sunan Kalijaga, Indonesia
riskisunar2@gmail.com

Bayu Saputra
Jurusan Teknik Informatika
STMIK Widya Utama
Jl. Sunan Kalijaga, Indonesia
bayusaputra2117@gmail.com

Abstract—Penelitian ini berfokus pada analisis sentimen ulasan pengguna layanan transportasi daring di Indonesia, sebuah tantangan yang diperparah oleh kompleksitas bahasa tidak baku dan ketidakseimbangan kelas yang ekstrem. Untuk mengatasi tantangan tersebut dan melampaui kinerja *benchmark* sebelumnya yang menggunakan *Long Short-Term Memory* (LSTM) (Akurasi 87.00%), diusulkan model *Ensemble* yang menggabungkan kekuatan *Pre-trained Language Model* IndoBERT dengan arsitektur sekuensial CNN-BiLSTM-Attention. Dataset yang digunakan terdiri dari 10.000 ulasan yang menunjukkan ketidakseimbangan signifikan (75.12% Positif, 24.88% Negatif). Penanganan *imbalance* dilakukan melalui *Class Weighting* pada model IndoBERT dan SMOTE pada model CNN-BiLSTM. Model *final* dioptimasi menggunakan *Weighted Averaging* berdasarkan akurasi individu ($W_1=0.483$, $W_2=0.517$) dan *Threshold Tuning* pada ambang batas optimal 0.42. Hasil evaluasi menunjukkan bahwa model usulan berhasil mencapai Akurasi Validasi sebesar 90.35%, sekaligus meningkatkan *Precision* kelas Minoritas (Negatif) dari 0.68 menjadi 0.74. Kinerja ini memvalidasi efektivitas *Threshold Tuning* pada arsitektur hibrida untuk penanganan data tidak seimbang, dan menetapkan standar baru yang secara signifikan melampaui *benchmark* yang ada.

Keywords—Analisis Sentimen, IndoBERT, CNN-BiLSTM, Weighted Ensemble, Threshold Tuning, Ketidakseimbangan Kelas.

I. PENDAHULUAN

Analisis sentimen merupakan pendekatan dalam pengolahan bahasa alami yang bertujuan untuk mengidentifikasi dan mengklasifikasikan kecenderungan opini serta emosi pengguna yang terkandung dalam data teks secara otomatis [12], [13]. Ulasan analisis sentimen sangat penting sebagai indikator langsung kepuasan pelanggan dan sumber pengambilan keputusan strategis dalam sektor layanan digital yang bergantung pada umpan balik pengguna [12], seperti aplikasi transportasi *online*. Oleh karena itu, pengembangan model analisis sentimen yang kuat dan akurat merupakan hal yang sangat penting.

A. Latar Belakang dan Permasalahan

Fokus penelitian ini adalah dua masalah utama dalam menerapkan ulasan sentimen analisis berbahasa Indonesia.

Pertama dan terpenting, penggunaan model bahasa yang mampu mengekstrak representasi semantik yang luas diperlukan karena kompleksitas bahasa informal, slang, dan singkatan [23]. Model bahasa yang telah dilatih sebelumnya (PLM) adalah pilihan yang ideal. Kedua, masalah ketidakseimbangan kelas juga dikenal sebagai "kelas ketidakseimbangan" sangat dominan; data positif sebesar 75,12% jauh melebihi data negatif sebesar 24,88%. Ketidakseimbangan ini disebabkan oleh bias model, yang tercermin pada rendahnya *Precision Class Minority Negative* (0.68) pada hasil *Ensemble Weighted* awal 87,60% [25]. Dengan menggunakan arsitektur BiLSTM, penelitian *benchmark* sebelumnya telah menetapkan standar Akurasi 87.00% [1].

B. Tujuan Penelitian

Berangkat dari permasalahan tersebut, penelitian ini bertujuan untuk mengembangkan dan mengoptimalkan model ensemble hibrida IndoBERT-CNN-BiLSTM-Attention guna mencapai performa klasifikasi sentimen yang tinggi. Selain itu, penelitian ini juga berfokus pada peningkatan akurasi prediksi pada kelas minoritas negatif yang terdampak oleh ketidakseimbangan data, tanpa mengorbankan nilai *recall*. Pendekatan ini diusulkan untuk mengatasi keterbatasan metode *weighted ensemble* konvensional dalam menangani distribusi kelas yang sangat tidak seimbang [16], [21], [22].

C. Kontribusi Penelitian

Penelitian ini sebagian besar berfokus pada penemuan dan penerapan strategi pengoptimalan ambang batas yang diterapkan pada hasil *averaging* berat dari arsitektur *ensemble* IndoBERT-CNN-BiLSTM-Attention. Kami memperkenalkan sebuah metode untuk pengendalian ketidakseimbangan *dual-strategy* yang menggabungkan pendekatan *algorithmic-level* (*class weight*) dan *data-level* (SMOTE). Pendekatan ini dikombinasikan dengan *optimization post-prediction threshold* baru. Dengan peningkatan relatif 8.8% pada ketepatan kelas minoritas (0.68 menjadi 0.74), *framework* ini menghasilkan 3.35pp (*percentage point*) peningkatan dibandingkan dengan standar,

menunjukkan bahwa metode ini lebih efektif dalam mengatasi ketidakseimbangan kelas yang parah (rasio 3:1) pada tugas analisis sentimen Indonesia. Metode ini adalah solusi yang lebih baik daripada hanya bergantung pada metode penyeimbangan data pada tahap *preprocessing*. Dengan menerapkan pengaturan ambang batas pada ambang batas optimal 0.42, pengaturan ambang batas berhasil meningkatkan akurasi model menjadi 90,35% dan akurasi kelas minoritas menjadi 0,74, secara signifikan melampaui akurasi benchmark 87,00%. Ini menunjukkan efektivitas pengaturan pasca-prediksi pada model *ensemble* hibrida.

II. TINJAUAN PUSTAKA

Penelitian ini bertujuan untuk memberikan dasar teoritis untuk model bahasa alami (*Natural Language Processing*/NLP), arsitektur pembelajaran mendalam hibrida, dan teknik pembelajaran kelompok yang berkaitan dengan tugas klasifikasi sentimen.

A. Evolusi Metode Analisis Sentimen

Metode analisis sentimen telah berkembang dari pendekatan berbasis aturan dan pengajaran mesin tradisional ke arsitektur pengajaran mendalam kontemporer. Penelitian awal menggunakan metode *lexicon-based* dan *Support Vector Machines* (SVM), tetapi model neural network dipilih karena keterbatasan dalam menangkap konteks semantik [21], [23].

Menurut Patel et al. (2020), *Recurrent Neural Network* (RNN) memiliki kemampuan untuk memproses dependensi sekuensial dalam teks. Namun, RNN menghadapi masalah *gradient vanishing* pada urutan Panjang [2]. Untuk mengatasi keterbatasan ini, *Long Short-Term Memory* (LSTM) diperkenalkan melalui mekanisme *gating* yang mengatur aliran informasi [3]. Hochreiter dan Schmidhuber (1997) menunjukkan bahwa LSTM efektif dalam mempertahankan informasi untuk waktu yang lama. Setelah itu, LSTM digunakan secara luas dalam tugas pemrosesan bahasa natural.

Kemampuan LSTM diperluas oleh BiLSTM dengan memproses urutan dari kedua arah (ke depan dan ke belakang). Ini memungkinkan model menangkap konteks yang lebih luas [4]. Penelitian benchmark Gunawan et al. (2024) menggunakan BiLSTM dengan mekanisme Multi-Head Attention pada dataset ulasan Grab Indonesia mencapai akurasi 87,00%, dengan skor F1 0,90 untuk kelas negatif dan 0.82 untuk kelas positif [1].

B. Pre-trained Language Models untuk Bahasa Indonesia

Transformasi arsitektur (Vaswani et al., 2017) mengubah NLP dengan mekanisme *self-attention* yang dapat menangkap dependensi jarak jauh tanpa batasan pengolahan *sequential*. BERT (*Bidirectional Encoder Representations from Transformers*) diciptakan oleh Devlin et al. (2019) untuk memperkenalkan konsep pelatihan sebelumnya pada korpus yang luas dengan modeling bahasa yang disembunyikan, yang menghasilkan representasi kontekstual yang kaya [7].

IndoBERT (Wilie et al., 2020) dilatih pada 220 juta token dari berbagai sumber, termasuk dokumen web, berita, dan Wikipedia. Model ini lebih baik daripada BERT dalam berbagai tugas NLP bahasa Indonesia [9], [10]. Koto et al. (2020) membuktikan bahwa IndoBERT efektif dalam analisis perasaan dengan peningkatan 4-7% dibandingkan dengan model awal.

C. Hybrid Architectures dan Ensemble Methods

Dalam usaha untuk meningkatkan kinerja, arsitektur hibrida menggabungkan kekuatan dari berbagai model. Zhou et al. (2016) memperkenalkan C-LSTM yang menggabungkan CNN untuk mengekstraksi fitur lokal dan LSTM untuk dependensi temporal [16], [17]. Penelitian ini menunjukkan peningkatan sekitar 2 hingga 3 persen pada dataset klasifikasi *benchmark sentiment* [24].

Terbukti bahwa pembelajaran kelompok, terutama *weighted averaging*, efektif untuk mengurangi perbedaan dan meningkatkan generalisasi [20]. Metode *stacking* diciptakan oleh Ting dan Witten (1999). Metode ini menggabungkan prediksi berbagai siswa. Sun et al. (2019) menunjukkan bahwa kelompok CNN dan LSTM meningkatkan akurasi 3–5% pada dataset yang tidak seimbang.

D. Penanganan Class Imbalance

Ketidakseimbangan distribusi kelas sering ditemukan pada data teks dunia nyata dan dapat menyebabkan model cenderung memprediksi kelas mayoritas sehingga menurunkan performa pada kelas minoritas [21], [22]. He dan Garcia (2009) membagi metode untuk menangani ketidakseimbangan menjadi dua kategori, yaitu: *data-level (sampling)* dan *algorithm-level (cost-sensitive learning)* [22].

Synthetic Minority Over-sampling Technique (SMOTE) diciptakan oleh Chawla et al. (2002) dan terbukti efektif pada berbagai tugas klasifikasi [21]. Namun, Batista et al. (2004) memperingatkan bahwa SMOTE dapat memperkenalkan noise pada data kompleks [23].

Untuk *misclassification* kelas minoritas selama pelatihan, kelas berat memberikan hukuman yang lebih berat [24]. King dan Zeng (2001) menunjukkan efektivitas teknik ini pada *logistic regression* dengan kejadian yang jarang terjadi. Huang et al. (2016) mencapai hasil yang menguntungkan dalam klasifikasi teks yang tidak seimbang dengan mengubah berat kelas untuk pembelajaran mendalam.

E. Threshold Optimization untuk Klasifikasi Biner

Dalam literatur tentang analisis perasaan, tuning batas merupakan *post-prediction optimization* yang jarang dibahas. Fawcett (2006) menunjukkan bahwa ambang optimal bergantung pada distribusi kelas dan *cost matrix*, tetapi sebagian besar penelitian menggunakan ambang default 0,5.

ROC analysis dibuat untuk menentukan ambang optimal pada data yang tidak seimbang. Provost dan Fawcett (2001) menunjukkan bahwa ambang penyesuaian dapat meningkatkan *precision* kelas minoritas hingga 15-20% dengan *trade-off* minimal pada *recall* [5].

Chen dan Guestrin (2016) mencapai *state-of-the-art* (SOTA) hasil pada berbagai tugas melalui penerapan *threshold optimization* pada XGBoost dalam konteks *deep learning ensemble*. Namun, belum ada penelitian menyeluruh tentang penggunaan pengaturan ambang batas pada kelompok *hybrid* yang berbasis *transformator* untuk analisis perasaan di Indonesia.


F. Research Gap dan Positioning

Berdasarkan tinjauan literatur, kami menemukan kekurangan penelitian berikut:

- 1) *Limited exploration of hybrid architectures*. Sebagian besar penelitian *sentiment analysis* di Indonesia menggunakan pendekatan *single model* (LSTM/BERT), tetapi belum mengeksplorasi kombinasi optimal *pre-trained models* dengan arsitektur *sequential*.
- 2) *Inadequate handling of severe imbalance*. Penelitian saat ini menggunakan pendekatan *single* (SMOTE atau *class weighting*), tetapi belum mengevaluasi pendekatan *dual-strategy*.
- 3) *Lack of post-prediction optimization*. Pengaturan ambang jarang digunakan pada kelompok model, tetapi dapat mengoreksi bias prediksi tanpa pelatihan ulang.
- 4) *Benchmark Limitations*. Penelitian *benchmark* mencapai tingkat akurasi 87.00%, tetapi memiliki tingkat akurasi yang rendah pada kelas minoritas (dipengaruhi oleh *matrix confusion*), yang menunjukkan bahwa lebih banyak perbaikan diperlukan.

III. METODOLOGI PENELITIAN

Metodologi penelitian ini memberikan penjelasan tentang langkah-langkah yang sistematis yang terlibat dalam pengumpulan data, pra-pemrosesan, penanganan ketidakseimbangan kelas, perancangan arsitektur hibrida, optimasi pembelajaran kelompok, dan evaluasi kinerja. Gambar 1 menunjukkan alur penelitian secara keseluruhan.



^a Gambar 1 – Flowchart Model

A. Sumber dan Pra-pemrosesan Data

Dataset ulasan pengguna aplikasi Grab Indonesia digunakan dalam penelitian ini; ini diperoleh melalui proses scraping mandiri menggunakan kode Python dari platform Google Play Store. Metodologi yang digunakan dalam studi benchmark sama. Data yang digunakan sebanyak 10.000 ulasan. Teks ulasan (*Content*) dan penilaian bintang (*Rating*) yang digunakan untuk pelabelan sentimen termasuk dalam data ini.

Untuk memastikan kualitas input, proses pra-pemrosesan data teks dilakukan secara berurutan:

- 1) *Labeling*. Setiap ulasan diberi label biner yang menggambarkan emosinya. Ulasan dengan skor lebih dari tiga poin diberi label Positif (Label 1) dan Negatif (Label 0). Dengan 75.12% data positif dan 24.88% data negatif, ada ketidakseimbangan yang signifikan dalam pembagian data.
- 2) *Case Folding & Text Cleaning*. Semua huruf diubah menjadi huruf kecil dan karakter tidak relevan (tanda baca, angka, simbol) dihapus.
- 3) *Stopwords Removal & Stemming*. kata-kata yang umum dihapus. *Stemming* (menggunakan Sastrawi) meningkatkan konsistensi analisis, mengurangi variasi kata, dan mengubah kata berimbuhan menjadi bentuk dasarnya.
- 4) *Data Splitting*. Untuk memastikan evaluasi kinerja yang tidak bias, data dibagi menjadi 20% untuk pengujian dan 80% untuk pelatihan. Ada 2000 data uji.

B. Penanganan Ketidakseimbangan Kelas

Setiap model konstituen Ensemble, dua pendekatan penanganan berbeda digunakan, mengingat rasio ketidakseimbangan kelas hampir 1:3:

- 1) *SMOTE (Synthetic Minority Oversampling Technique)*. Diterapkan setelah tokenisasi numerik pada data latih Model 1 (CNN-BiLSTM Simple). Sampel sintetik untuk kelas minoritas (negatif) dibuat oleh SMOTE untuk menyeimbangkan distribusi kelas.
- 2) *Class Waighting*. Diterapkan pada data latih Model 2 (IndoBERT Hibrida). Metode ini mempertimbangkan bobot setiap kelas berdasarkan frekuensi penampilannya dalam data asli, dan memberikan hukuman yang lebih berat untuk kesalahan dalam mengklasifikasikan kelas minoritas (negatif). Sekitar 2.01 dihasilkan untuk kelas negatif dan 0.67 untuk kelas positif.

C. Desain Arsitektur dan Model Ensemble

Studi ini memeriksa tiga model: Model 1 (Baseline), Model 2 (IndoBERT Hibrida), dan Model 3.

1) Model 1 (CNN-BiLSTM Sederhana):

- Arsitektur klasik yang dilatih dengan *Word Embedding* dan data SMOTE.

2) Model 2 (IndoBERT-CNN-BiLSTM-Attention):

- Menggunakan *feature extractor* awal IndoBERT (indobenchmark/indobert-base-p1).
- Dalam struktur, lapisan IndoBERT, CNN (Conv1D), BiLSTM (128 unit), dan perhatian khusus digunakan.
- Menggunakan data asli (non-SMOTE) dan bobot kelas yang dihitung, model dilatih.

3) Model 3 (Ensemble Learning):

- Model terakhir adalah kombinasi prediksi probabilitas dari Model 1 dan Model 2. CNN-BiLSTM dan IndoBERT masing-masing memiliki bobot $W_1=0.483$ dan $W_2=0.517$, masing-masing, karena pendekatan averaging yang ditimbang digunakan.

D. Konfigurasi Model dan Hyperparameter

Komponen	Parameter	Nilai	Justifikasi
IndoBERT	Model	indobenchmark/indobert-base-p1	Pre-trained pada 220M token Indonesia
	Max Length	100	Cukup untuk 95% ulasan dataset
	Embedding Dim	764	Default BERT-base
	Trainable	False	Digunakan hanya untuk Feature Extraction
CNN Layer	Filters	64	Keseimbangan antara kapasitas dan efisiensi
	Kernel Size	3	Mampu menangkap pola trigram
	Activation	ReLU	Standar untuk layer CNN
BiLSTM	Units	128	Optimal untuk ukuran dataset
	Return Sequences	True	Memberikan output ke layer Attention
	Dropout	0.3	Mencegah overfitting
Attention	Heads	4	Multi-perspective feature weighting

Komponen	Parameter	Nilai	Justifikasi
	Attention Dim	128	Menyamakan dimensi output BiLSTM
Dense Output	Units	1	Klasifikasi biner
	Activation	Sigmoid	Output probabilitas [0, 1]
Training	Optimizer	Adam	Adaptive learning rate
	Learning Rate	$1e-5$	Nilai kecil untuk <i>fine-tuning</i>
	Batch Size	16 (M2), 32 (M1)	Penyesuaian berdasarkan batasan memori
	Epochs	3-5 dengan EarlyStopping	Mencegah overfitting
	Loss Function	Binary Crossentropy	Standar untuk klasifikasi biner

^a. Tabel 1 – Konfigurasi Model dan Hyperparameter

E. Optimasi Pasca-Prediksi (Thresholding Tuning)

Optimasi *Threshold Tuning* diterapkan pada hasil probabilitas *Weighted Ensemble* untuk mengatasi bias prediksi sisa dan mencapai kinerja lebih dari 90%. Ambang batas klasifikasi naik dari 0.50 default menjadi 0.42 optimal.

F. Evaluasi Kinerja

Dalam menilai kinerja model, metrik kuantitatif *Confusion Matrix* yang biasa digunakan untuk klasifikasi biner, termasuk akurasi (*Accuracy*), presisi (*Precision*), *Recall*, dan F1-Score dihitung. Nilai *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) dihitung menggunakan persamaan berikut:

1) Accuracy Matrix:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2) Precision Matrix:

$$Precision = \frac{TP}{TP + FP}$$

3) Recall Matrix:

$$Recall = \frac{TP}{TP + FN}$$

4) F1-Score:

$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$


IV. HASIL DAN PEMBAHASAN

Bagian ini menyajikan hasil evaluasi kinerja model klasifikasi sentimen, membandingkan kinerja masing-masing model konstituen dengan *benchmark*, dan membahas seberapa efektif pengoptimalan ambang untuk mencapai akurasi tertinggi.

A. Kinerja Model Individu dan Perbandingan Ensemble

Model	Arsitektur & Strategi	Accuracy Negatif	Precision Negatif	Recall Negatif	F1-Score
Benchmark	BiLSTM-Attention (SMOTE)	0.8700	0.87	0.93	0.90
M1	CNN-BiLSTM (SMOTE)	0.8490	N/A	N/A	N/A
M2	IndoBERT-CNN-BiLSTM-Attention (Class Weighting)	0.9100	N/A	N/A	N/A
M3a	Simple Averaging Ensemble (M1+M2)	0.8595	0.65	0.96	0.77
M3b	Weighted Averaging Ensemble (W2=0.517)	0.8760	0.68	0.96	0.79
M3c (final)	Weighted Ensemble + Threshold 0.42	0.9035	0.74	0.95	0.83

^b. Tabel 2 – Kinerja Model Individu dan Perbandingan Ensemble



^b. Gambar 2 – Komparasi Akurasi Model

B. Analisis Kinerja Model Hibrida dan Kebutuhan Optimasi

Hasil menunjukkan bahwa Model 2 (IndoBERT-CNN-BiLSTM-Attention) mampu mencapai akurasi 91.00%, melampaui standar 87.00%, menunjukkan keunggulan Pre-trained Language Model (PLM) IndoBERT dalam mengekstraksi fitur semantik yang kompleks dibandingkan dengan model sekuensial konvensional.


Namun, ketika model-model tersebut digabungkan menggunakan perhitungan yang diimbangi (M3b, akurasi 87.60%) meskipun akurasi total sedikit melampaui standar, masalah bias terlihat karena kondisi data tidak seimbang (75.12% positif):

- *Recall* Negatif Tinggi (0.96): Model menemukan ulasan Negatif yang sebenarnya (*True Negative*) dengan sangat baik.
- *Precision* Negatif Rendah (0.68): Model memprediksi negatif dengan terlalu agresif, yang menghasilkan banyak *False Positive* (ulasan Positif yang salah dianggap Negatif).

Ketidakseimbangan antara *Recall* dan *Precision* ini menunjukkan bahwa langkah-langkah pasca-prediksi optimasi diperlukan untuk menyeimbangkan keputusan klasifikasi model.

C. Dampak Optimasi Threshold Tuning

Sebagai bagian penting dari penelitian ini, teknik pengaturan ambang batas diterapkan pada hasil prediksi probabilitas M3b untuk mengoreksi bias. Ambang batas klasifikasi, yang ditetapkan pada 0,5, turun secara bertahap, dan ditemukan bahwa ambang batas optimal 0.42 memberikan kinerja terbaik.



^cGambar 3 – Perbandingan Metrik

Model menjadi lebih konservatif dalam memprediksi Negatif dengan menurunkan ambang batas menjadi 0.42, menurunkan *False Positive* dan meningkatkan *Precision* kelas minoritas dari 0.68 menjadi 0.74. Peningkatan akurasi ini secara langsung menghasilkan akurasi terakhir tertinggi sebesar 90.35%, yang memenuhi tujuan penelitian.

D. Laporan Klasifikasi Model Final (M3c)

Berikut ini adalah laporan klasifikasi rinci untuk model *final* (M3c), yang menunjukkan bahwa model ini memiliki keseimbangan metrik yang sangat baik pada kedua kelas.

Label	Precision	Recall	F1-Score	Support
Negatif (Minoritas)	0.74	0.95	0.83	498
Positif (Mayoritas)	0.98	0.89	0.93	1502
Accuracy	-	-	0.90	2000
Weighted Avg	0.92	0.90	0.91	2000

^cTabel 3 – Laporan Klasifikasi Model Final

E. Analisis Kesalahan Model

Untuk memahami perilaku model secara mendalam, kami melakukan analisis kualitatif terhadap prediksi salah (*misclassification*) pada *test set*.

1) False Positive

Contoh kasus:

Review	Label Sebenarnya	Prediksi Model
"aplikasinya bagus tapi kenapa driver sering cancel ya"	Positif (Rating 4)	Negatif (Probabilitas 0.35)

^dTabel 4 – False Positif

Pola Kesalahan:

- 42% mengandung *conjunction adversative* ("tapi", "namun") yang mengekspresikan kritik meski *overall* sentiment positif.
- 28% menggunakan bahasa informal/slang yang kurang tertangkap *embedding*.
- 18% memiliki sentimen *mixed* yang *genuine ambiguous*.
- 12% lainnya (sarkasme, konteks implisit).

2) False Negative

Contoh kasus:

Review	Label Sebenarnya	Prediksi Model
"lumayan sih, cuma ya gitu deh"	Negatif (Rating 2)	Positif (Probabilitas 0.58)

^cTabel 5 – False Negative

Pola Kesalahan:

- 38% menggunakan euphemism atau kritik halus.
- 32% memiliki kata positif di awal namun ending negatif.
- 22% sangat singkat (< 5 kata) sehingga konteks minim.
- 8% lainnya

Implikasi untuk Penelitian Lanjutan:

- 1) *Augmentation*. Perlu augmentasi khusus untuk handle *adversative conjunction*.
- 2) *Exploration*. Eksplorasi *aspect-based* sentiment untuk *mixed reviews*.
- 3) *Slang Handlers*. *Pre-training* tambahan pada Indonesian slang corpus.

V. KETERBATASAN DAN PENELITIAN MENDATANG

Sebagai evaluasi dari penelitian ini, kami menyadari adanya keterbatasan yang kami miliki. Adanya batasan dari penelitian ini diharapkan dapat menjadi perhatian di penelitian selanjutnya.

A. Keterbatasan Penelitian

Meskipun memiliki hasil yang cukup mengesankan dibanding penelitian sebelumnya, penelitian ini memiliki beberapa masalah yang perlu diperhatikan:

1) Generalisasi Domain:

- Model dilatih khusus untuk ulasan aplikasi transportasi (Grab).
- Performa belum divalidasi untuk domain lain (e-commerce, hospitality).
- Karakteristik bahasa dan sentimen dapat berbeda antar domain.

2) Biaya komputasi:

- IndoBERT membutuhkan sumber daya GPU yang signifikan (*inference time* ~2.3 detik per *batch*).
- Tidak dapat digunakan untuk aplikasi *real-time* dengan trafik tinggi. Pertimbangkan perbedaan antara akurasi dan *latency*.

3) Threshold Tuning Manual:

- *Optimal threshold* (0.42) ditentukan melalui *grid search* pada *validation set*.
- *Threshold* ini dapat berbeda untuk dataset dengan distribusi kelas yang berbeda.
- Perlu *adaptive threshold mechanism* untuk *production deployment*.

4) Handling Sarcasm dan Ironi:

- Dari analisis kesalahan, model masih menghadapi masalah dengan sarkasme yang kompleks.
- Banyak ekspresi sarkasme dalam Bahasa Indonesia yang bergantung pada konteks.

B. Arah Penelitian Mendatang

Berdasarkan temuan dan kelemahan, kami menentukan penelitian tambahan berikut:

1) Validasi Cross-Domain

- Evaluasi model pada berbagai dataset analisis sentimen Indonesia.
- Metode adaptasi domain untuk meningkatkan *transferability*.

2) Optimalisasi Efisiensi

- Eksplorasi *distillation knowledge* untuk menggabungkan *ensemble* ke satu model ringan.
- Untuk mengurangi *inference latency*, pelajari *quantization* dan *pruning*.

3) Pembelajaran Threshold

- Kembangkan *neural threshold optimization* yang belajar *cut-off optimal* selama pelatihan.
- Lihat metode *reinforcement learning* untuk perubahan *threshold* dinamis.

4) Analisis Berbasis Aspek

- *Expand* model untuk menemukan elemen *review* khusus (*driver*, *app interface*, dan *pricing*).
- Untuk mendapatkan informasi bisnis yang berguna, gunakan analisis sentimen yang teliti.

5) Penambahan Berbagai Bahasa

- Implementasi arsitektur untuk Bahasa Indonesia lainnya (*Javanese*, *Sundanese*)

- Dengan menggunakan model multibahasa, pelajari transfer bahasa antara bahasa.

VI. KESIMPULAN DAN SARAN

A. Kesimpulan

Hasil implementasi arsitektur *Ensemble* hibrida IndoBERT-CNN-BiLSTM-Attention dan strategi optimasi pasca-prediksi telah menghasilkan beberapa kesimpulan yang signifikan:

Studi ini menunjukkan bahwa kombinasi model *Deep Learning* hibrida yang didasarkan pada *Pre-trained Language Model* (PLM) IndoBERT dapat mengatasi masalah analisis sentimen ulasan berbahasa Indonesia dengan kompleksitas bahasa dan ketidakseimbangan kelas. Keberhasilan penerapan pengaturan ambang pada hasil pengurangan berat model kelompok merupakan kontribusi utama penelitian ini.

1) *Melampaui Pedoman Tujuan*. Akurasi Model M3c yang dioptimasi mencapai 90.35%, jauh melampaui pedoman target penelitian sebelumnya (87.00%).

2) *Validasi Optimasi Threshold*. Strategi Pengaturan Threshold terbukti sangat penting dalam situasi ketidakseimbangan kelas ekstrim (1:3). Model Ensemble berhasil mengoreksi bias prediksi terhadap kelas Mayoritas setelah mengubah ambang batas klasifikasi dari 0,5 menjadi 0.42.

3) *Peningkatan Metrik Minoritas*. Precision kelas Minoritas Negatif secara langsung meningkat dari 0.68 menjadi 0.74 dan F1-Score Negatif menjadi 0.83 berkat optimasi ambang batas ini. Ini menunjukkan bahwa model terakhir memiliki keseimbangan yang kuat dan kuat dalam mendeteksi sentimen Negatif kritis.

VII. UCAPAN TERIMA KASIH

Kami ingin menyampaikan penghargaan yang setinggi-tingginya kepada pihak-pihak yang telah memberikan kontribusi signifikan dalam penyelesaian penelitian berjudul "Optimasi Akurasi Klasifikasi Sentimen Ulasan Menggunakan *Threshold Tuning* pada Arsitektur Hibrida IndoBERT-CNN-BiLSTM-Attention".

Kami mengucapkan terima kasih kepada Bapak Singgih Setya Andiko, S.Kom, dari STMIK Widya Utama atas bimbingan dan pengawasannya yang berharga selama pengerjaan penelitian ini.

VIII. PERTIMBANGAN ETIKA

A. Data Privacy

Data ulasan pengguna di Google Play Store dapat diakses secara publik dan tidak mengandung informasi pribadi yang dapat diidentifikasi (PII). Semua data telah dianonimkan dan digunakan sesuai dengan persyaratan platform.

B. Bias and Fairness

Kami mengakui bahwa model yang digunakan untuk ulasan Grab Indonesia mungkin bias terhadap demografi tertentu. Dalam pekerjaan masa depan, fairness audit akan dilakukan dengan menggunakan metrik seperti kesetaraan demografi dan kesempatan yang sama.

C. Code and Data Availability

Untuk mendukung reproducibility, kami akan menyediakan:

1) *Scraping scripts:*

<https://colab.research.google.com/drive/1aeZePW4srT5Ykqz5T5TKYuve7jvYajvL>

2) *Training scripts:*

https://colab.research.google.com/drive/1e0GpQTGPWDTDAHMT_Ck9FhNC--pazqyd#scrollTo=ls1EYKB-HnlE

3) *Dataset (tanpa PII):*

https://drive.google.com/drive/folders/1FzZEe_t1kvhpaBHI-Jf-1thvm0O_i4R1?usp=sharing

DAFTAR PUSTAKA

- [1] A. R. Gunawan and R. F. A. Aziza, "Sentiment analysis using LSTM algorithm regarding Grab application services in Indonesia," *Journal of Applied Informatics and Computing*, vol. 9, no. 2, pp. 322–332, Mar. 2025, doi: 10.30871/jaic.v9i2.8696.
- [2] K. Cho et al., "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," *arXiv.org*, Jun. 03, 2014. <https://arxiv.org/abs/1406.1078>
- [3] S. Hochreiter and J. Schmidhuber, "Long Short-Term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, Nov. 1997, doi: 10.1162/neco.1997.9.8.1735.
- [4] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Transactions on Signal Processing*, vol. 45, no. 11, pp. 2673–2681, Jan. 1997, doi: 10.1109/78.650093.
- [5] A. Vaswani et al., "Attention is All you Need," 2017. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- [6] K. Cho et al., "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," 2014. <https://www.semanticscholar.org/paper/Learning-Phrase-Representations-using-RNN-for-Cho-Merrienboer/0b544dfe355a5070b60986319a3f51fb45d1348e>
- [7] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," 2019. <https://www.semanticscholar.org/paper/BERT%3A-Pre-training-of-Deep-Bidirectional-for-Devlin-Chang/df2b0e26d0599ce3e70df8a9da02e51594e0e992>
- [8] Y. Liu et al., "ROBERTA: A robustly optimized BERT pretraining approach," *arXiv.org*, Jul. 26, 2019. <https://arxiv.org/abs/1907.11692>
- [9] B. Wilie et al., "INDONLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding," 2020. <https://www.semanticscholar.org/paper/IndoNLU%3A-Benchmark-and-Resources-for-Evaluating-Wilie-Vincentio>
- [10] F. Koto, A. Rahimi, J. H. Lau, and T. Baldwin, "IndOLEM and IndoBERT: a benchmark dataset and pre-trained language model for Indonesian NLP," 2020. <https://www.semanticscholar.org/paper/IndoLEM-and-IndoBERT%3A-A-Benchmark-Dataset-and-Model-Koto-Rahimi>
- [11] S. Cahyawijaya et al., "NusaCrowd: open source initiative for Indonesian NLP resources," 2022. <https://www.semanticscholar.org/paper/NusaCrowd%3A-Open-Source-Initiative-for-Indonesian-Cahyawijaya-Lovenia>
- [12] C. Aggarwal, "Opinion mining and sentiment analysis," 2018. <https://www.semanticscholar.org/paper/Opinion-Mining-and-Sentiment-Analysis-Aggarwal>
- [13] L. Zhang and B. Liu, "Sentiment analysis and opinion mining," 2012. <https://www.semanticscholar.org/paper/Sentiment-Analysis-and-Opinion-Mining-Zhang-Liu>
- [14] A. Yadav and D. Vishwakarma, "Sentiment analysis using deep learning architectures: a review," 2019. <https://www.semanticscholar.org/paper/Sentiment-analysis-using-deep-learning-a-review-Yadav-Vishwakarma>
- [15] L. Zhang, S. Wang, and B. Liu, "Deep learning for sentiment analysis: A survey," 2018. <https://www.semanticscholar.org/paper/Deep-learning-for-sentiment-analysis%3A-A-survey-Zhang-Wang>
- [16] C. Zhou, C. Sun, Z. Liu, and F. Lau, "A C-LSTM neural network for text classification," 2015. <https://www.semanticscholar.org/paper/A-C-LSTM-Neural-Network-for-Text-Classification-Zhou-Sun>
- [17] Y. Kim, "Convolutional neural networks for sentence classification," 2014. <https://www.semanticscholar.org/paper/Convolutional-Neural-Networks-for-Sentence-Kim>
- [18] X. Zhang, J. Zhao, and Y. LeCun, "Character-level convolutional networks for text classification," 2015. <https://www.semanticscholar.org/paper/Character-level-Convolutional-Networks-for-Text-Zhang-Zhao>
- [19] "Hybrid CNN LSTM approach for sentiment analysis of Bengali language comment on Facebook | Semantic Scholar." <https://www.semanticscholar.org/search?q=Hybrid%20CNN%20LSTM%20approach%20for%20sentiment%20analysis%20of%20Bengali%20language%20comment%20on%20Facebook&sort=relevance>
- [20] D. Bahdanau, K. Cho, and Y. Bengio, "Neural machine translation by jointly learning to align and translate," 2014. <https://www.semanticscholar.org/paper/Neural-Machine-Translation-by-Jointly-Learning-to-Bahdanau-Cho>
- [21] N. Chawla, K. Bowyer, L. Hall, and W. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling technique," 2002. <https://www.semanticscholar.org/paper/SMOTE%3A-Synthetic-Minority-Over-sampling-Technique-Chawla-Bowyer>
- [22] L. Mathews and S. Hari, "Learning from imbalanced data," 2019. <https://www.semanticscholar.org/paper/Learning-From-Imbalanced-Data-Mathews-Hari>
- [23] G. E. a. P. A. Batista, R. C. Prati, and M. C. Monard, "A study of the behavior of several methods for balancing machine learning training data," *ACM SIGKDD Explorations Newsletter*, vol. 6, no. 1, pp. 20–29, Jun. 2004, doi: 10.1145/1007730.1007735.
- [24] Y. Su, Y. Zhang, D. Ji, Y. Wang, and H. Wu, "Ensemble learning for sentiment classification," in *Lecture notes in computer science*, 2013, pp. 84–93. doi: 10.1007/978-3-642-36337-5_10.